¿Cómo funciona Alexa? Implementando una aplicación de Key Word Spotting.

Facilitador: Cristian Yarib Bautista Villalpando

Un poco de mis antecedentes…

- Ingeniero en electrónica (automatización y control)
  - Instituto Tecnológico de Aguascalientes, 2010
- Maestría en Sistemas Embebidos (MSE)
  - INFOTEC, 2023
- 6 años de experiencia docente a nivel superior
- Integrador de proyectos:
  - Automatización, robótica y control (PLC, instrumentación, DAQ)
  - Desarrollo de soluciones en tarjetas embebidas (domótica, didácticas, industria…)
  - Procesamiento digital de señales (audio, visión, sensores en general)
  - Sistemas inteligentes (*Artificial intelligence* and *machine learning)*
- Melómano (sistemas de producción musical, arte/tecnología)

¿Qué se espera que se lleven de este curso?

- Aplicar el ciclo de vida para el desarrollo de aplicaciones en IA
- Conocer y analizar los principios para el tratamiento de señales de audio, sus principales características y técnicas de preprocesamiento.
- Entrenar, probar y mejorar modelos enfocados al reconocimiento de voz.
- Evaluar modelos para tomar decisiones de post-entrenamiento.
- Entender las limitaciones cuando modelos de IA se despliegan en sistemas con pocos recursos computacionales.
- Conocer las técnicas de optimización típicas del TinyML

¿Cómo funciona Alexa? Implementando una aplicación de Key Word Spotting.

Facilitador: Cristian Yarib Bautista Villalpando

Tema 1.
Introducción a las aplicaciones de activación por voz

1.1 ¿Qué es una aplicación de activación por voz (KWS: Keyword spotting)?

- Es parte del área del conocimiento **“Reconocimiento del habla”**.
- El **reconocimiento de palabras clave** detecta una palabra o frase corta dentro de una secuencia de audio. Esta técnica también se conoce como **descubrimiento de palabra clave (KWS en inglés)**.
- El caso de uso más común del reconocimiento de palabras clave es la **activación por voz de los asistentes virtuales**.
- **Tras el reconocimiento** de la palabra clave, **se lleva a cabo una acción específica** de cada escenario.

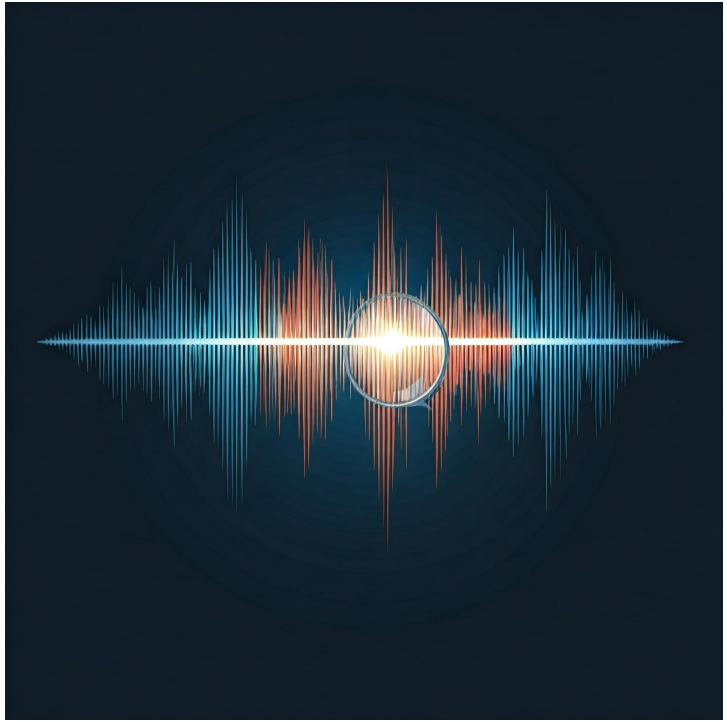

1.2 Casos de uso y ejemplos

Smart Home Devices

Automotive Systems

Customer Satisfaction

https://www.youtube.com/watch?v=AG7yiTscfL8

https://www.youtube.com/watch?v=3XbnzfBjmZk

https://www.youtube.com/watch?v=-SSv93OWUFo

1.3 Componentes clave y consideraciones

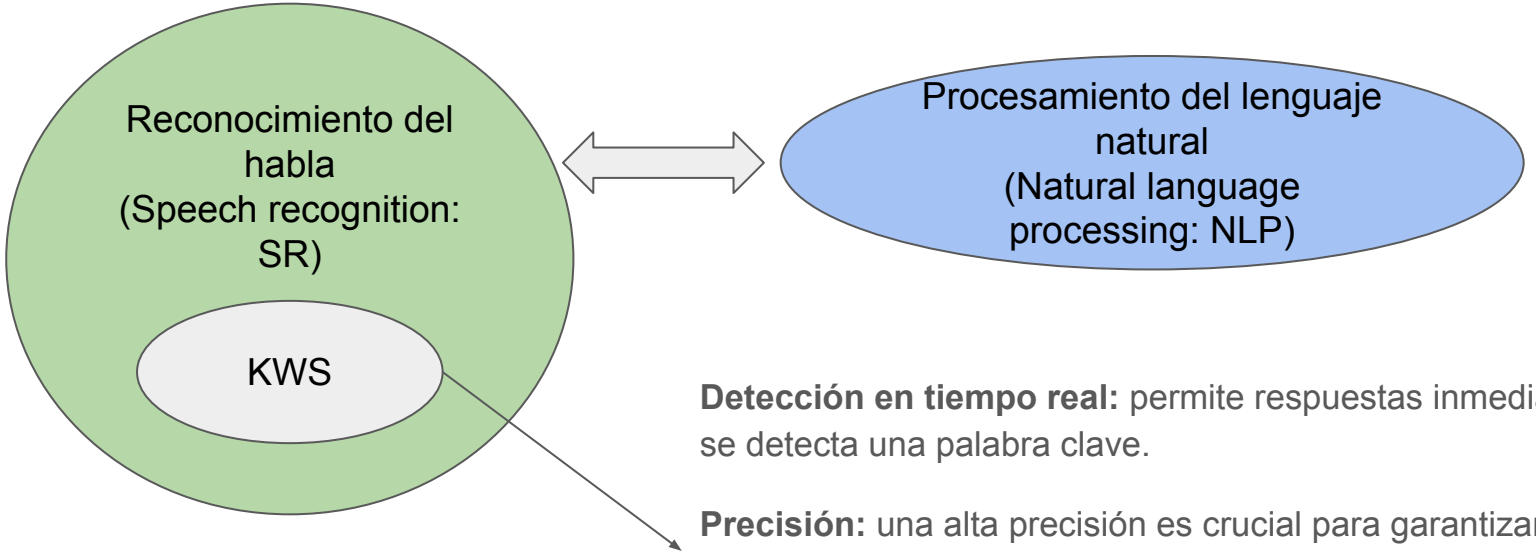

Detección en tiempo real: permite respuestas inmediatas cuando se detecta una palabra clave.

Precisión: una alta precisión es crucial para garantizar que se reconoce la palabra clave correcta en un entorno ruidoso.

Baja latencia: El sistema debe detectar las palabras clave con un retardo mínimo para garantizar una experiencia de usuario fluida.

Arquitectura de cascada de los asistentes de voz y etapas

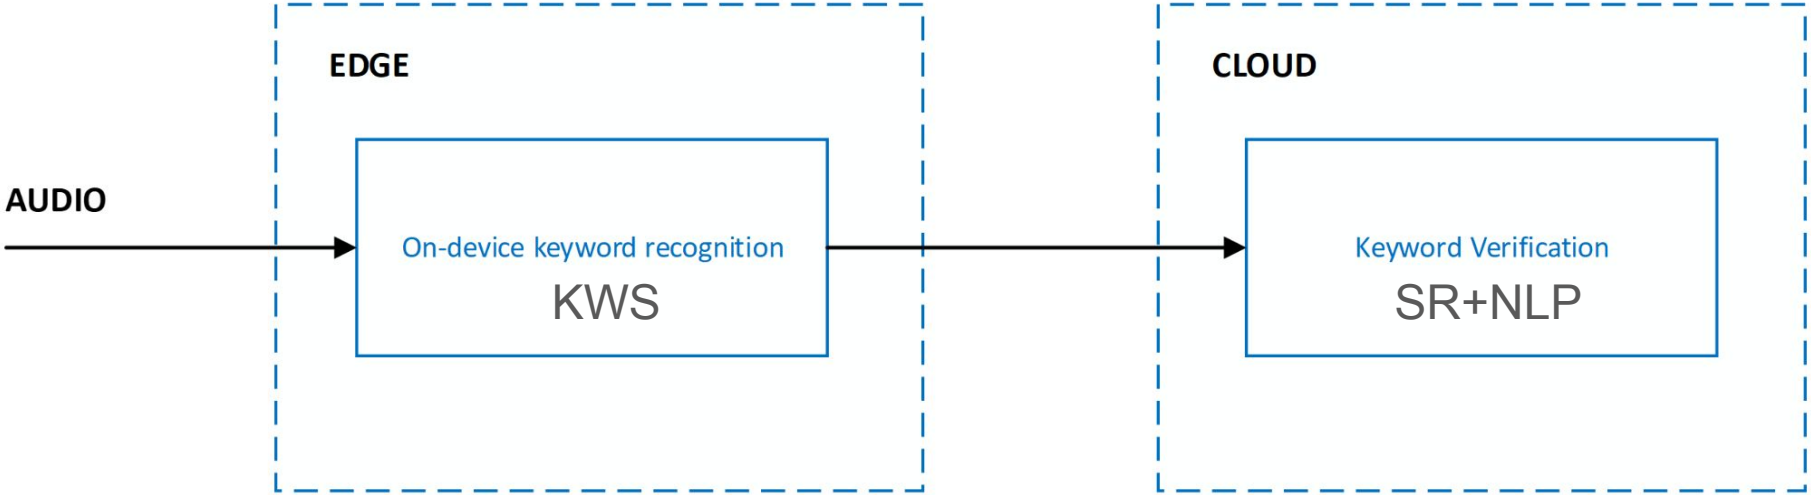

Por lo general, **los asistentes virtuales siempre están a la escucha**. El KWS actúa como límite de privacidad para el usuario. Un requisito de palabra clave actúa como una barrera que **impide que el audio no relacionado del usuario pase del dispositivo local a la nube.**

Para equilibrar la precisión, la latencia y la complejidad computacional, **el KWS se implementa como un sistema de varias fases.** Para todas las fases más allá de la primera, el audio solo se procesa si la fase anterior reconoce la palabra clave de interés.

La **precisión del reconocimiento** de palabras clave se mide mediante las métricas siguientes:

- **Tasa de aceptación correcta o Tasa de Verdaderos Positivos**: mide la capacidad del sistema para reconocer la palabra clave que pronuncia un usuario.
- **Tasa de aceptación falsa o Tasa de Falsos Positivos**: mide la capacidad del sistema para filtrar el audio que no sea la palabra clave pronunciada por un usuario final.

El objetivo es **maximizar la tasa de aceptación correcta al tiempo que se minimiza la tasa de aceptación falsa.**

El sistema actual está diseñado para detectar una palabra clave o frase **precedida de un breve silencio**. Usualmente no se admite la detección de una palabra clave en medio de una frase o expresión.

Beneficios y retos

Beneficios:

Mayor eficacia y productividad: La detección de palabras clave permite la interacción manos libres con los sistemas.

Mejora de la experiencia del cliente: Al identificar rápidamente palabras clave específicas y responder con prontitud, las empresas pueden ofrecer una experiencia de cliente más fluida y eficiente

Perspectivas y tendencias del mercado: La detección de palabras clave se puede utilizar para supervisar los comentarios de los clientes en tiempo real, identificando problemas o solicitudes comunes.

Ahorro de costes: Al reducir la necesidad de transcripción o interpretación manual del discurso, la detección de palabras clave puede reducir los costes operativos en sectores como la atención al cliente o la sanidad.

Retos

Ruido e interferencias: El ruido de fondo, como el tráfico, las conversaciones o los sonidos ambientales, puede interferir en la capacidad del sistema. Los algoritmos de filtrado y cancelación de ruido son esenciales.

Falsos positivos y falsos negativos: Los falsos positivos se producen cuando el sistema detecta erróneamente una palabra clave, mientras que los falsos negativos se producen cuando no la detecta.

Acentos y variaciones lingüísticas: Las variaciones en la pronunciación o los acentos regionales pueden complicar la detección. Los modelos de aprendizaje automático deben entrenarse con datos de voz diversos para tener en cuenta estas variaciones y mejorar la solidez del sistema.

Rendimiento en tiempo real: En entornos críticos, como los sistemas sanitarios o de automoción, el rendimiento en tiempo real es crucial.

Privacidad de los datos: Dado que los sistemas de detección de palabras clave a menudo procesan datos de voz sensibles, garantizar la privacidad de los datos y cumplir con regulaciones como GDPR es esencial.

Tema 2.
Conceptos básicos de procesamiento de audio

2.1 Entendiendo las señales de audio

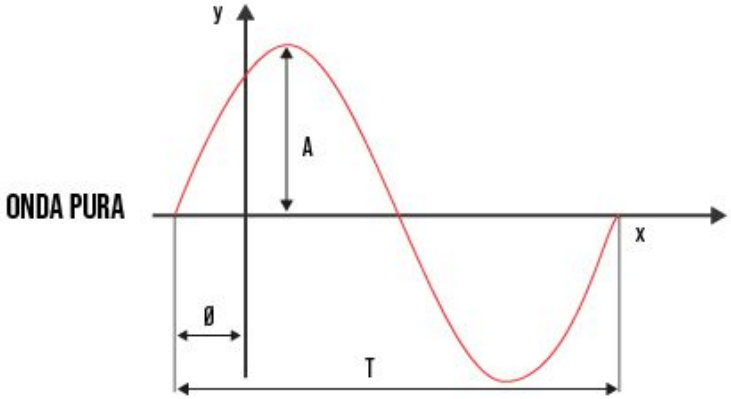

Tiempo continuo

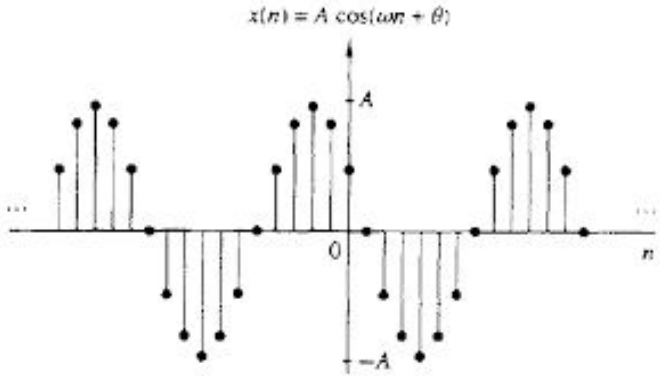

Tiempo discreto

$$F = \frac{1}{T}$$

$$F_s = \frac{1}{T_s}$$

Pueden ser mono o estereo

Tasa de muestreo y profundidad de bits

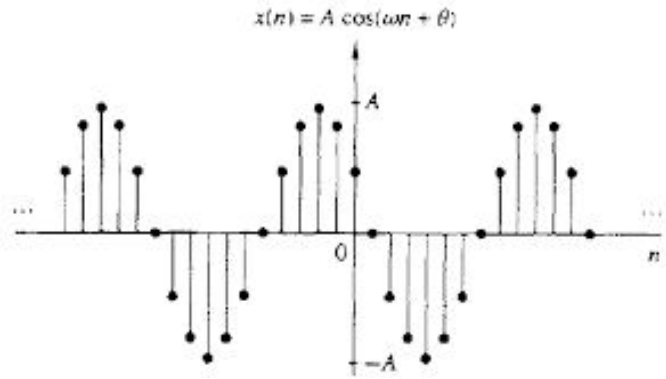

$$ADC$$

Analog to digital convertor

$$F_s = \frac{1}{T_s}$$

La frecuencia de muestreo, también conocida como tasa de muestreo, es la cantidad de muestras que se toman por segundo de una señal analógica para convertirla en una señal digital. Esta cantidad se expresa en hertzios (Hz), donde 1 Hz representa una muestra por segundo.

$$Resolution$$

La **profundidad de bits (bit depth)** en audio se refiere al número de bits utilizados (n) para representar la amplitud de cada muestra de audio digital. Cuanto mayor sea la profundidad de bits, mayor será la precisión de la representación de la amplitud y, por lo tanto, mejorará la calidad del sonido y el rango dinámico. $numero\ de\ valores = 2^n$

Ejemplos y ejercicios

8 bits: Usado en los primeros celulares y juegos de video. Sensación de “vintage”

16 bits: Común para CD y muchas aplicaciones de audio digital, ofrece un buen equilibrio entre calidad y tamaño de archivo.

24 bits: A menudo se utiliza en la producción de audio profesional para obtener mayor calidad y rango dinámico.

32 bits flotantes: Se utiliza internamente en las estaciones de trabajo de audio digital (DAW) para obtener mayor margen y flexibilidad durante la edición.

1. ¿Cuántos son los números de valores posibles para guardar las amplitudes en cada caso?
2. Si la Fs=16KHz, ¿Cada cuánto tiempo se toma una muestra?
3. Con la misma Fs, si se capturan 3 segundos de audio, ¿cuántas muestras habrán al final?
4. Si se toma una muestra cada 125uS, ¿cuál es la frecuencia de muestreo?
5. A la frecuencia anterior obtenida, ¿a cuánto tiempo de captura corresponden 2000 muestras?

Conceptos relevantes

Teorema de Nyquist:

También conocido como teorema de muestreo, establece que, para poder reconstruir fielmente una señal analógica a partir de sus muestras digitales, la frecuencia de muestreo debe ser al menos el doble de la frecuencia más alta presente en la señal original. Esta frecuencia mínima de muestreo se conoce como frecuencia de Nyquist.

Condición de Nyquist: Fs >= 2 * Fmax.

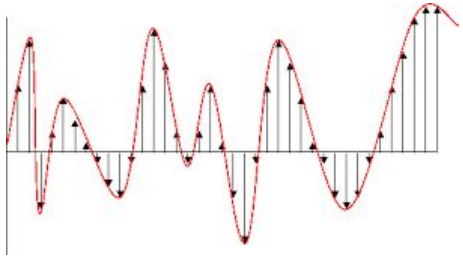

Teorema de Fourier

Establece que cualquier señal o función, incluso aquellas que no son sinusoidales (como una forma de onda cuadrada o un sonido complejo), puede ser descompuesta en una suma de ondas sinusoidales de diferentes frecuencias, amplitudes y fases. Estas ondas sinusoidales, cuando se suman, reconstruyen la señal original.

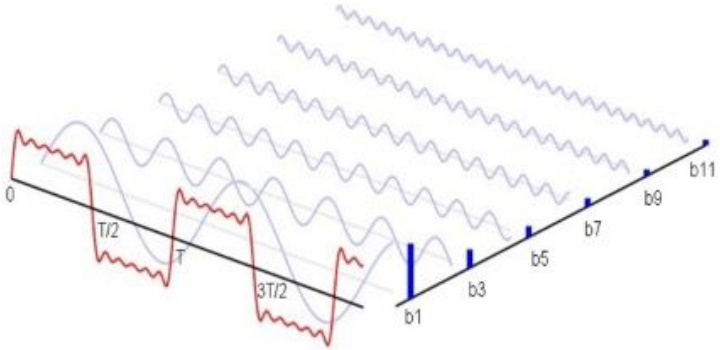

Conceptos relevantes

Armónicos:

Los armónicos en audio son componentes de un sonido que tienen frecuencias que son múltiplos enteros de la frecuencia fundamental. Estos armónicos son los que dan a un sonido su color o timbre, haciéndolo único. La combinación de la fundamental y sus armónicos define el sonido de un instrumento o voz.

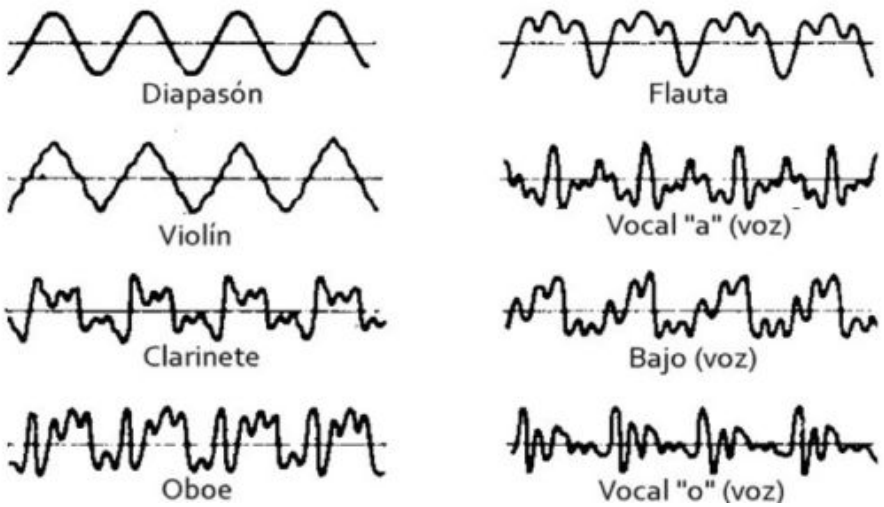

Preguntas

¿Cuál es el valor usual de Fs para el audio comercial?

¿Cuál es el rango de frecuencia de la voz humana?

¿Cuál es el rango audible típico humano?

2.2 Algunos formatos de archivos de audio típicos

Sin compresión, compresión con pérdida o compresión sin pérdida

Formatos con pérdida (lossy):

MP3 (MPEG-1 Audio Layer III): Es uno de los formatos más populares y conocidos, utilizado para la compresión de audio con pérdida.

AAC (Advanced Audio Coding): Un formato con pérdida, desarrollado como sucesor de MP3, que ofrece una mejor calidad de sonido a una tasa de bits similar.

WMA (Windows Media Audio): Formato de compresión desarrollado por Microsoft, similar a MP3, pero más popular en Windows.

Formatos sin pérdida (lossless):

AIFF (Audio Interchange File Format): Similar a WAV, pero desarrollado por Apple para almacenar audio de alta calidad.

FLAC (Free Lossless Audio Codec): Un formato de código abierto que ofrece compresión sin pérdida, similar a WAV.

ALAC (Apple Lossless Audio Codec): El formato sin pérdida de Apple, similar a FLAC.

WAV (Waveform Audio Format): Un formato de archivo sin comprimir, estándar de audio en Windows, que almacena audio sin pérdida de calidad.

Características de los archivos WAV

Una señal WAV es un formato de archivo de audio digital sin compresión, ampliamente utilizado para almacenar audio en alta calidad. Es popular entre profesionales del audio y aquellos que buscan editar audio sin pérdida de calidad.

No comprimido: No utiliza algoritmos de compresión, lo que significa que los archivos WAV pueden ser significativamente más grandes que otros formatos como MP3.

Alta calidad: Preserva la calidad original del audio sin pérdida de información.

PCM (Modulación por Código de Pulsos): Utiliza este método para codificar los datos de audio, dividiéndolos en pequeñas muestras para obtener la máxima calidad posible.

Frecuencia de muestreo común: Un valor común es 44.1 kHz, aunque también se pueden usar otros valores como 48 kHz.

Ideal para: Edición de audio, masterización, grabación y almacenamiento de audio de alta calidad.

Una señal cruda capturada y después del ADC se puede considerar audio WAV

2.3 Herramientas para procesamiento de audio (SW y bibliotecas)

librosa

pyAudio

Manipulate audio data using Pydub

SciPy

python-sounddevice

Tema 3.
Introducción al aprendizaje profundo para audio

3.1 Visión general del aprendizaje profundo aplicado a tareas de audio

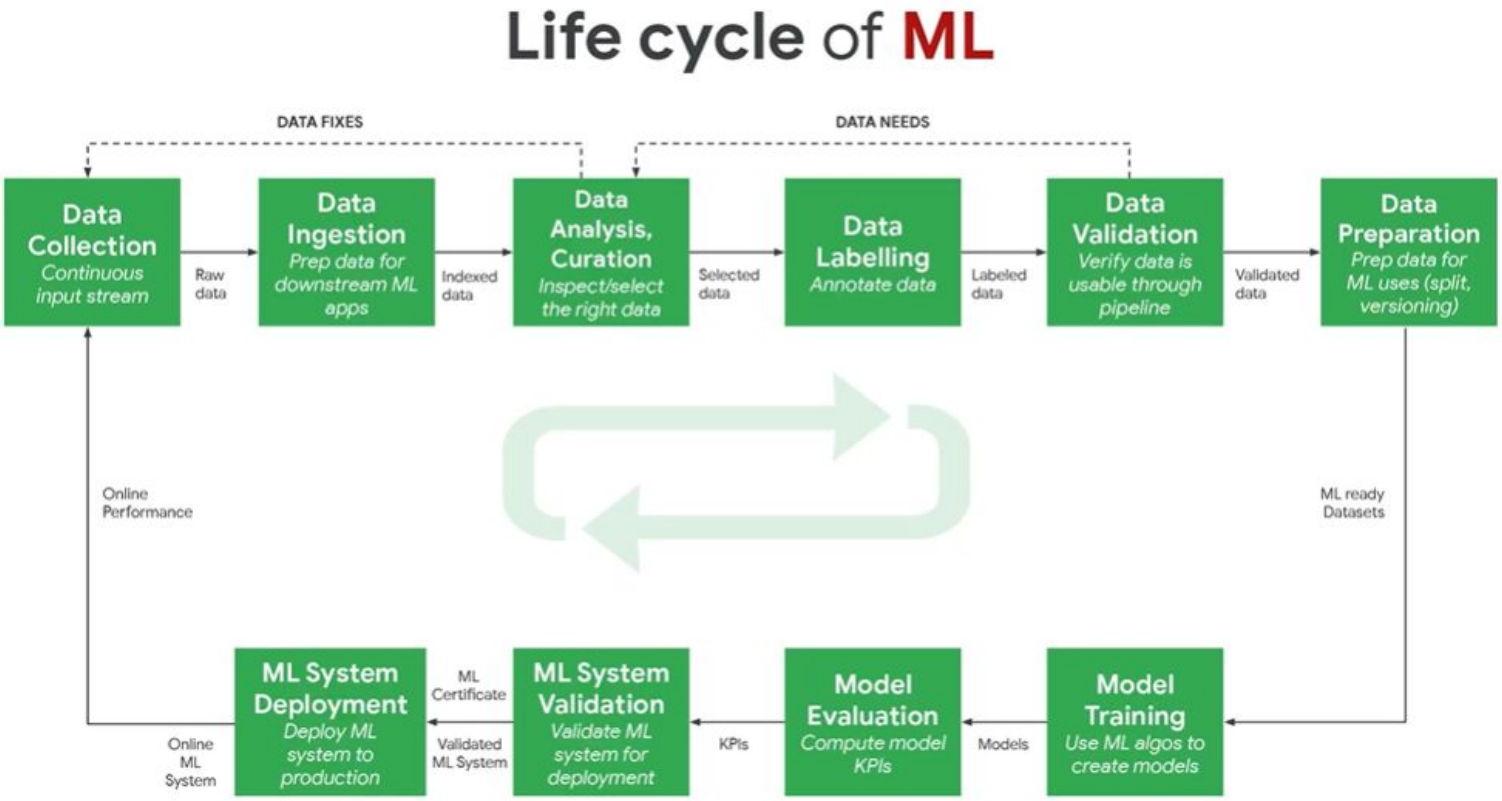

Life cycle of ML

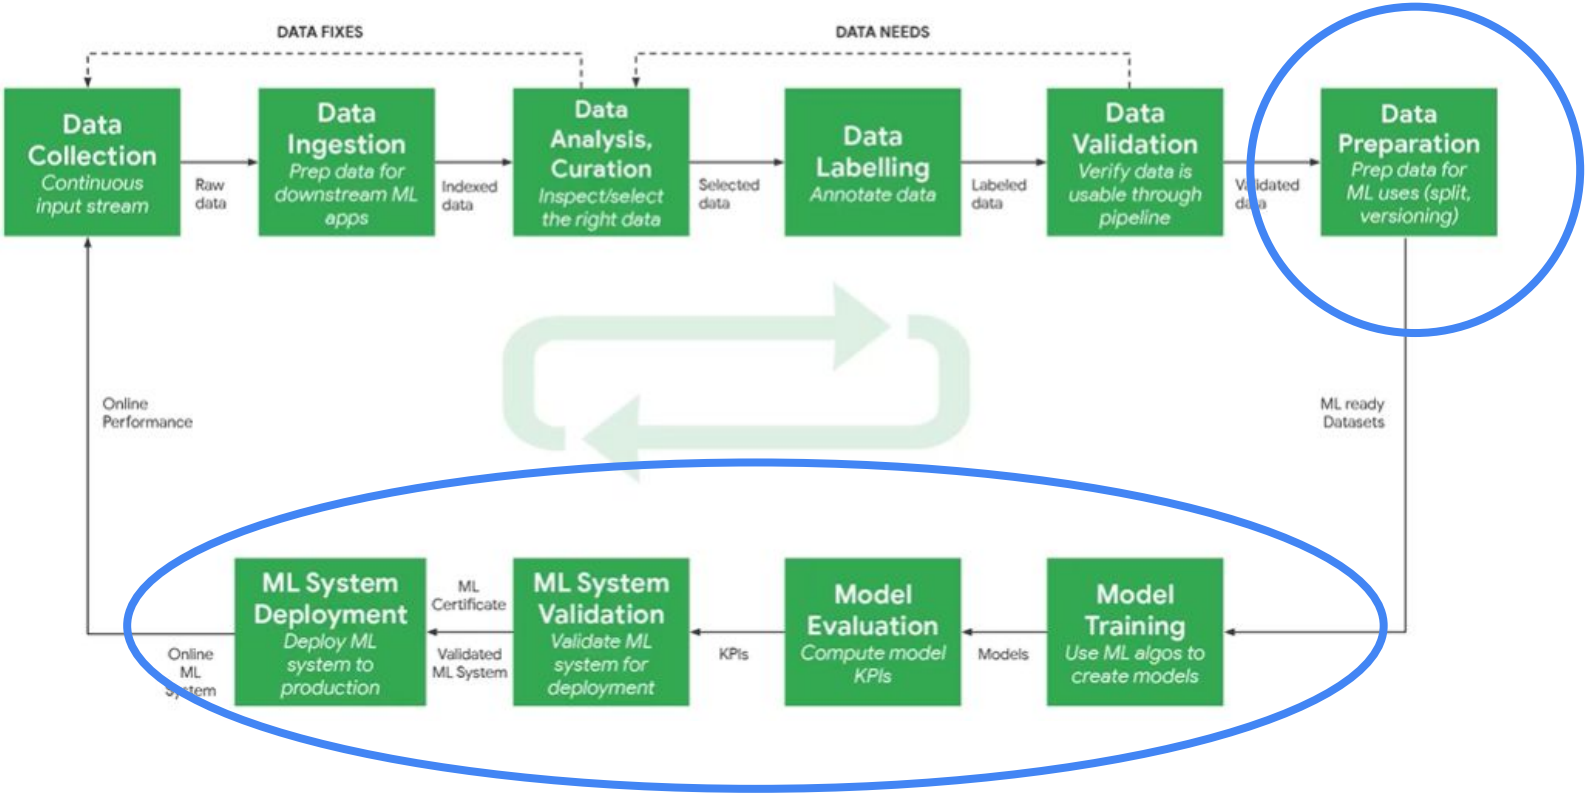

En bloques generales…

Durante el diseño y desarrollo…

Capturar audios para entrenar y limpieza

Preprocesamiento 1
Filtrado
Nivelado
Ecualizado

Extracción de características relevantes a la aplicación

Entrenamiento y evaluación

En el despliegue…

Captura continua de audio

Preprocesamiento 1
Filtrado
Nivelado
Ecualizado

Extracción de características usadas en el entrenamiento

Inferencia y acción

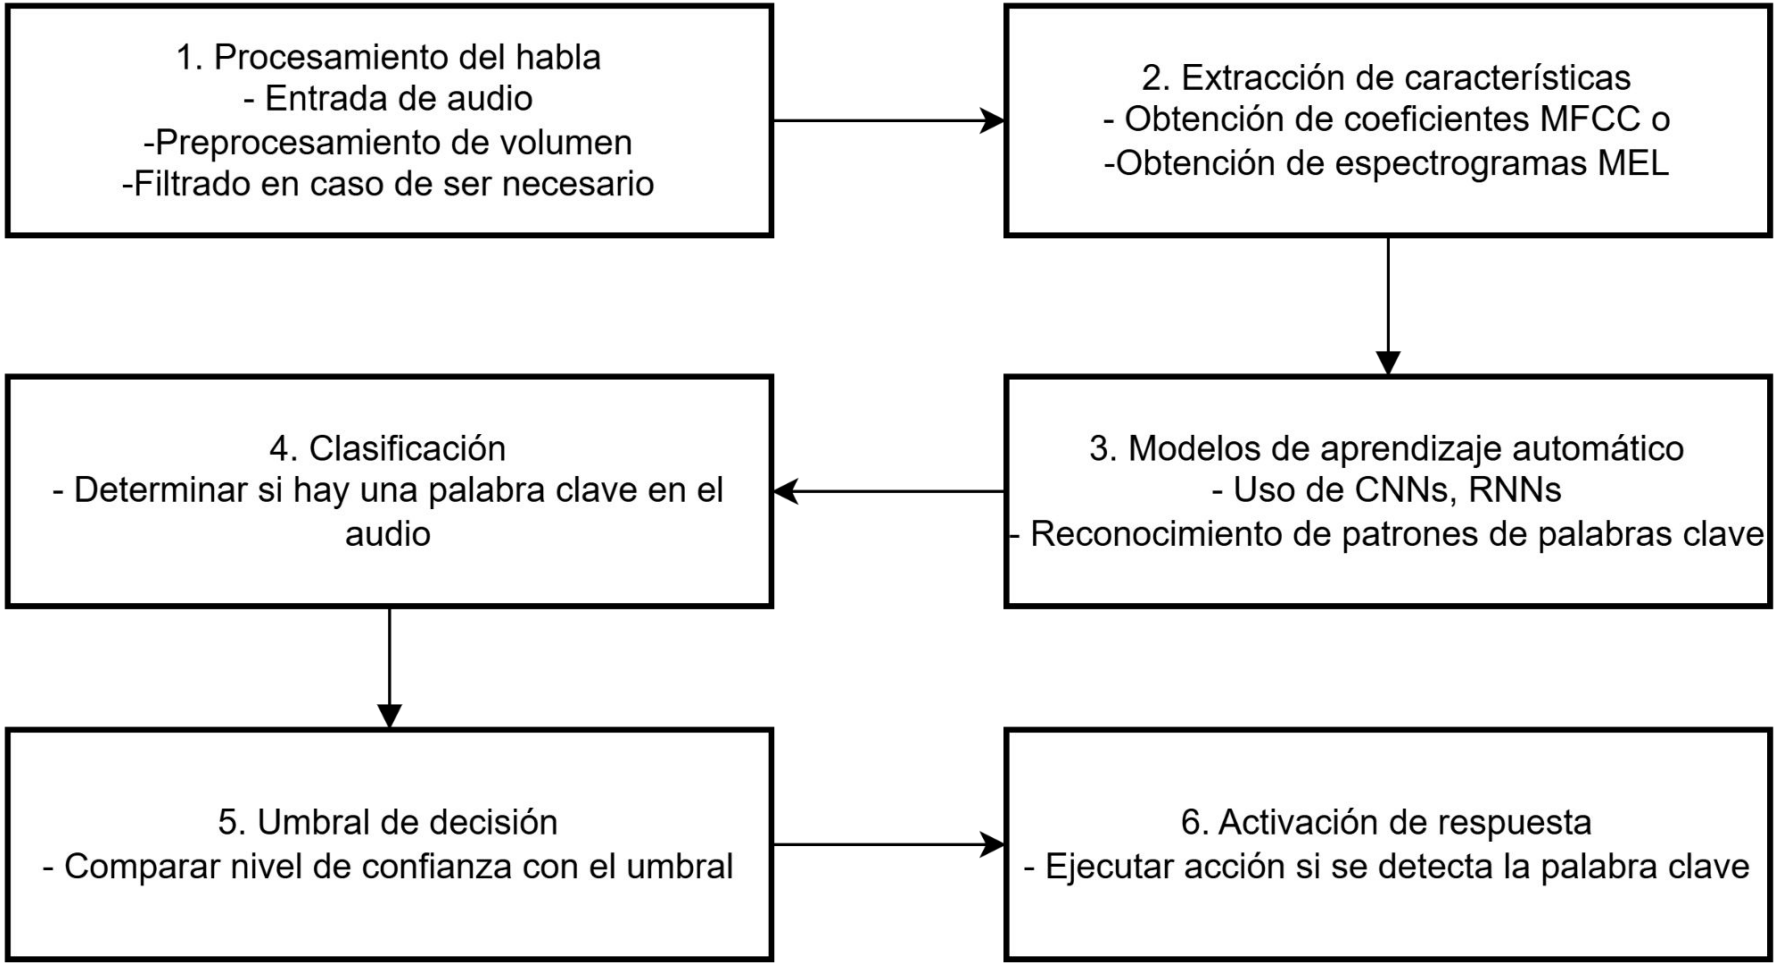
1. Procesamiento del habla
- Entrada de audio
-Preprocesamiento de volumen
-Filtrado en caso de ser necesario
2. Extracción de características
- Obtención de coeficientes MFCC o
-Obtención de espectrogramas MEL
3. Modelos de aprendizaje automático
- Uso de CNNs, RNNs
- Reconocimiento de patrones de palabras clave
4. Clasificación
- Determinar si hay una palabra clave en el audio
5. Umbral de decisión
- Comparar nivel de confianza con el umbral
6. Activación de respuesta
- Ejecutar acción si se detecta la palabra clave

3.2 Tareas comunes de audio: clasificación, transcripción y detección de palabras clave.

1. Clasificación de Audio

Descripción: Consiste en etiquetar un segmento de audio según su categoría o tipo.

Objetivo: Identificar automáticamente la naturaleza del sonido.

Ejemplos de aplicación:

- Reconocer si un audio contiene música, voz, ruido ambiental, aplausos, etc.
- Detectar emociones en la voz (felicidad, enojo, tristeza).
- Clasificar sonidos ambientales (tráfico, pájaros, lluvia) para sistemas IoT o vigilancia. Técnicas usadas:
- Redes neuronales convolucionales (CNN) para extraer características espectrales.
- Modelos como YAMNet o VGGish (preentrenados para clasificación de audio).

3.2 Tareas comunes de audio: clasificación, transcripción y detección de palabras clave.

2. Transcripción de Audio (Speech-to-Text, STT)

Descripción: Convertir el habla en texto escrito.

Objetivo: Obtener una representación textual fiel de lo dicho en el audio.

Ejemplos de aplicación:

- Subtitulado automático de videos o reuniones (Zoom, YouTube).
- Asistentes de voz (Siri, Alexa, Google Assistant).
- Transcripción de entrevistas o conferencias médicas/legales.
  Técnicas usadas:
- Modelos de lenguaje basados en redes neuronales recurrentes (RNN) o transformers (ej: Whisper de OpenAI, DeepSpeech).
- Procesamiento de lenguaje natural (NLP) para corregir errores y contextualizar.

3.2 Tareas comunes de audio: clasificación, transcripción y detección de palabras clave.

3. Detección de Palabras Clave (Keyword Spotting, KWS)

Descripción: Identificar palabras o frases específicas en un flujo de audio.

Objetivo: Actuar ante comandos vocales sin necesidad de transcribir todo el audio.

Ejemplos de aplicación:

- Activación por voz ("Hey Siri", "OK Google").
- Monitoreo de llamadas para detectar palabras sensibles (fraude, insultos).
- Sistemas de seguridad que reaccionan a gritos de "ayuda" o alarmas.
  Técnicas usadas:
- Modelos livianos como TDNN (Time-Delay Neural Networks) o pequeños transformers optimizados para dispositivos edge (ej: TensorFlow Lite).
- Espectrogramas + redes neuronales para patrones acústicos.

Comparación rápida

Tarea	Entrada	Salida	Complejidad
Clasificación	Audio crudo	Etiqueta (ej: "música")	Media
Transcripción	Habla	Texto	Alta
Detección KWS	Audio continuo	Presencia de palabra	Baja/Media

Ejercicios

Ejercicios prácticos durante la sesión: utilizando jupyter notebook (1 Manipulacion basica de audio).

1. Instalar Audacity
2. Visualización en Audacity
3. Manejo de audios individuales (carga, respuesta en tiempo y frecuencia)
4. Manipulación de batches (varios archivos de audio a la vez).

Ejercicios para después de clase:

1. Revisa la actividad que está dentro del Jupyter.
2. Comparte tus resultados en el foro.

Tema 4.
Trabajando con conjuntos de datos (datasets) de audio

4.1 Visión general del conjunto de datos Google Speech Commands

Algunos datasets populares para diferentes fines:

LibriSpeech ESC-50 Common Voice GTZAN Genre Collection

RAVDESS Google Speech Commands

- Para voz: LibriSpeech o Common Voice.
- Para sonidos no vocales: ESC-50.
- Para emociones: RAVDESS.
- Para comandos simples: Google Speech Commands.

4.1 Visión general del conjunto de datos Google Speech Commands

Finalidad: Detección de palabras clave (Keyword Spotting).

Descripción:

a. 65,000 clips de 1 segundo con 30 palabras clave ("yes", "no", "stop", etc.).
b. Formato WAV, 16 kHz, 16 bits, mono.
c. Diseñado para sistemas de voz en dispositivos edge.

Usos comunes:

d. Entrenar modelos livianos para asistentes de voz (ej: "OK Google").

Enlace: TensorFlow Datasets

https://www.kaggle.com/datasets/neehakurelli/google-speech-commands

4.1 Visión general del conjunto de datos Google Speech Commands

Contenido del Dataset

- Palabras clave (30 clases):
  - Comandos básicos: *"yes"*, *"no"*, *"stop"*, *"go"*, *"left"*, *"right"*, *"up"*, *"down"*.
  - Dígitos del 0 al 9: *"zero"*, *"one"*, ..., *"nine"*.
  - Otras palabras: *"bed"*, *"bird"*, *"cat"*, *"dog"*, *"happy"*, *"house"*, *"marvin"*, *"sheila"*, *"tree"*, *"wow"*.
- Ruido de fondo y silencios: Incluye muestras de *"background_noise"* para mejorar la robustez del modelo.

Estructura del Dataset

- Dividido en 3 conjuntos:
  - Entrenamiento (train): ~51,000 audios.
  - Validación (validation): ~6,700 audios.
  - Pruebas (test): ~6,800 audios.
- Etiquetas: Archivos CSV con la ruta del audio y su palabra asociada.

4.1 Visión general del conjunto de datos Google Speech Commands

Ventajas

✅ Diseñado para edge computing: Audios cortos y livianos.

✅ Diversidad de voces: Grabaciones de más de 2,000 personas.

✅ Balanceado: Distribución uniforme de palabras clave.

Limitaciones

❌ Solo inglés: No incluye otros idiomas.

❌ Entorno controlado: La mayoría de audios son en condiciones silenciosas (poco ruido realista).

7.1 Preparación del conjunto de datos

División básica del dataset para la evaluación del modelo

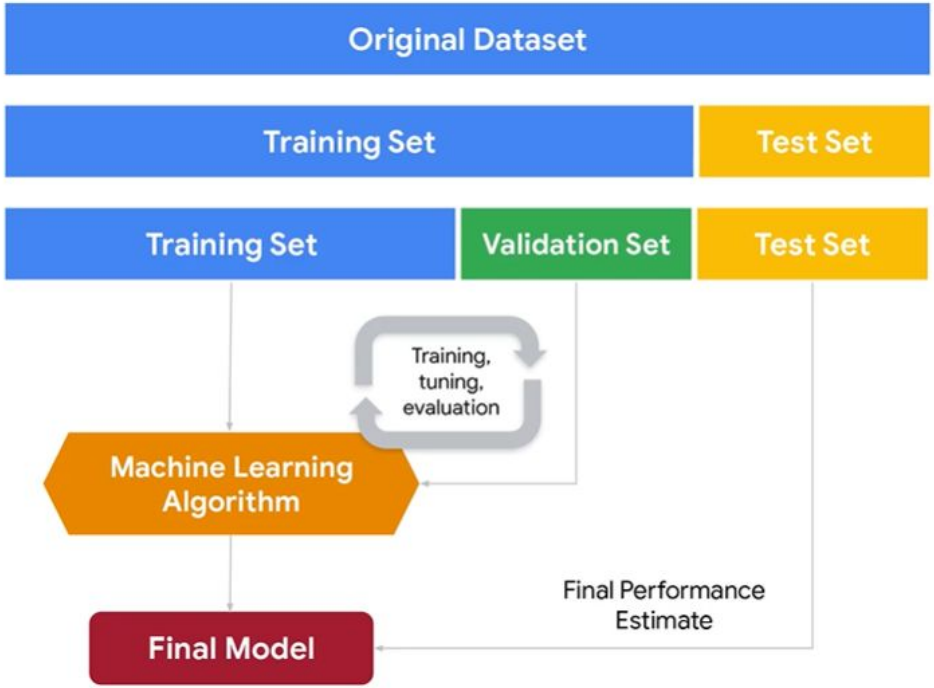

4.2 Carga y exploración del conjunto de datos usando TensorFlow Dataset (tfds)

Ejercicio:

1. Analizar primera parte del Jupyter “MeIA Audio”, título Tema 4.
2. Completa las líneas de código necesarias para que ejecute. Presta mucha atención durante la explicación para que puedas hacerlo correctamente.
3. Manipula el directorio para solo cargar 3 clases. Comprende cómo lograr personalizar el dataset de acuerdo a tus necesidades.

Tema 5.
Extracción de características de audio

5.1 Representaciones en el dominio del tiempo vs el dominio de la frecuencia

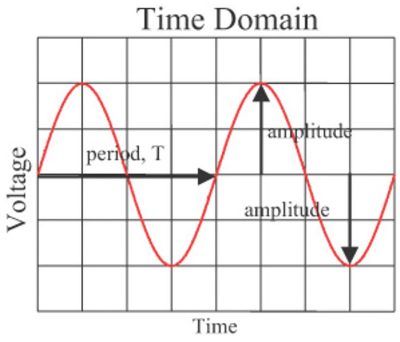

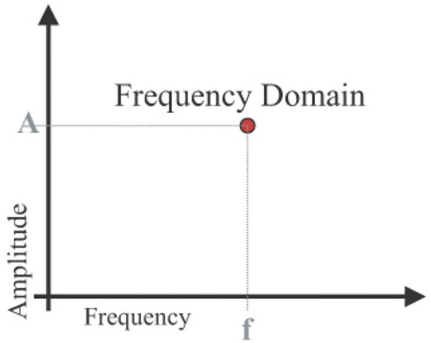

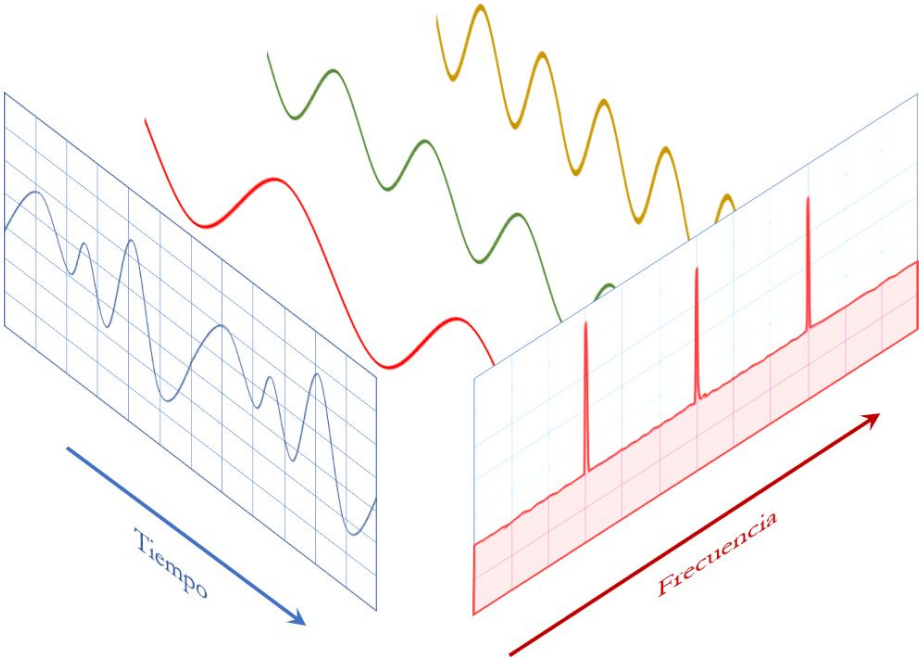

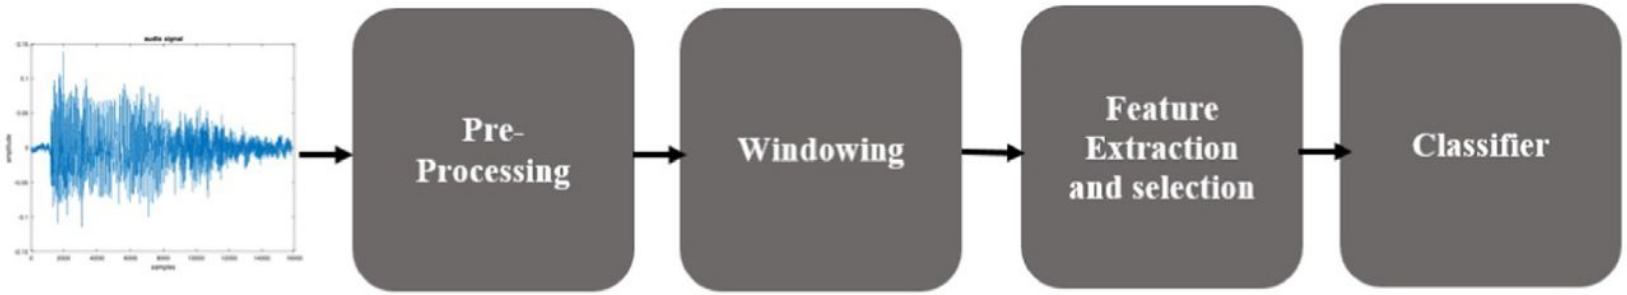

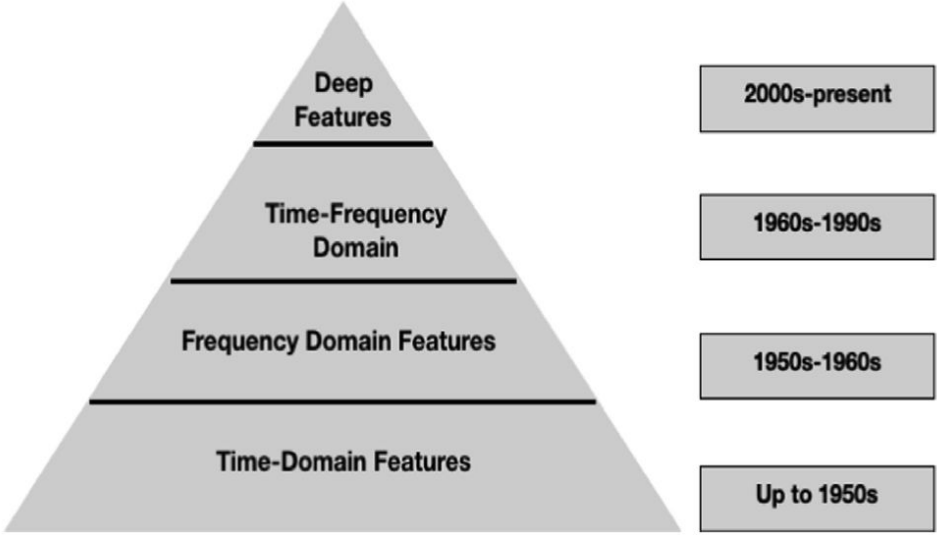

Referencia: Sharma, G., Umapathy, K., & Krishnan, S. (2020). Trends in audio signal feature extraction methods. *Applied Acoustics, 158*, 107020. https://doi.org/10.1016/j.apacoust.2019.107020

Típicas de caractesísticas

1. Características Basadas en Tiempo

Se calculan directamente de la forma de onda en el dominio temporal.

2. Características Basadas en Frecuencia

Requieren transformar la señal al dominio frecuencial (usando FFT).

3. Características Basadas en Tiempo-Frecuencia

Analizan la señal en ambos dominios simultáneamente.

4. Características Profundas (Deep Features)

Son representaciones de alto nivel extraídas automáticamente por redes neuronales profundas (como CNNs, Transformers o Autoencoders) a partir de señales de audio crudas o características preprocesadas (ej. espectrogramas).

Diferencia clave:

- Tiempo: Forma de onda cruda.
- Frecuencia: Análisis espectral estático.
- Tiempo-Frecuencia: Evolución espectral dinámica.
- Deep Features: No son diseñadas manualmente: Se aprenden de los datos durante el entrenamiento.

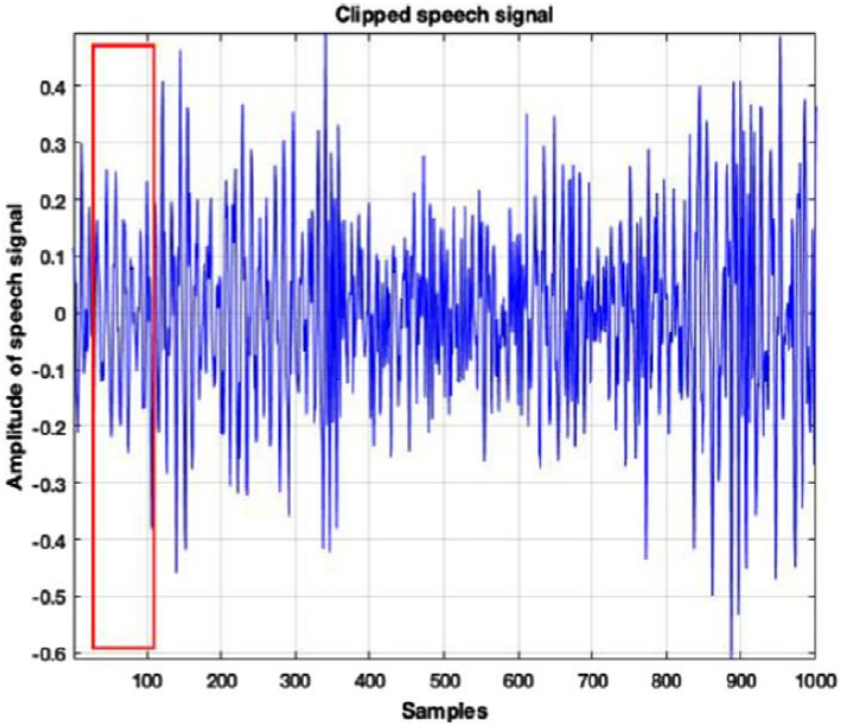
Clipped speech signal
Amplitude of speech signal
Samples
0.4
0.3
0.2
0.1
0
-0.1
-0.2
-0.3
-0.4
-0.5
-0.6
100
200
300
400
500
600
700
800
900
1000

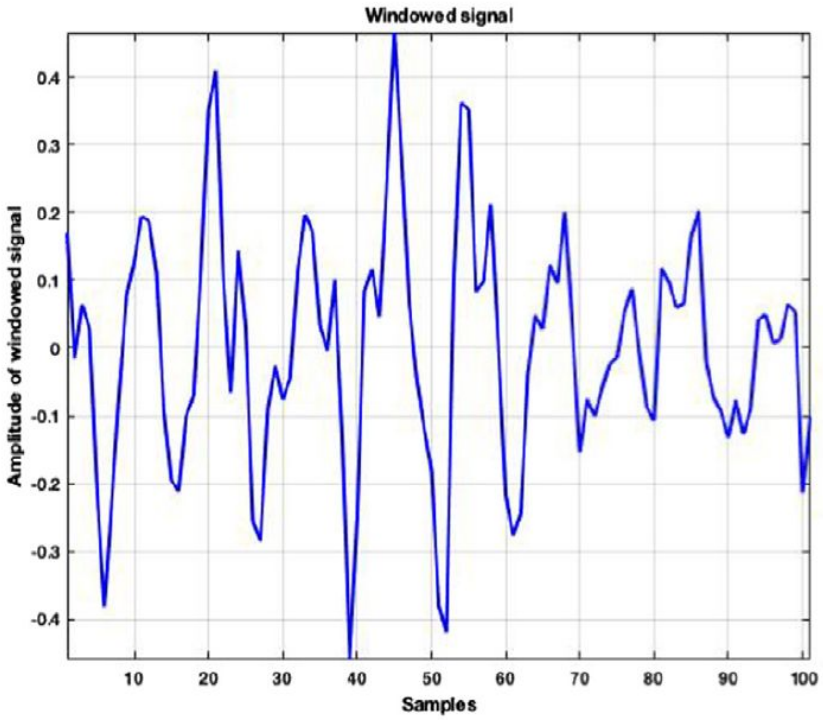
Windowed signal
Amplitude of windowed signal
Samples
0.4
0.3
0.2
0.1
0
-0.1
-0.2
-0.3
-0.4
10
20
30
40
50
60
70
80
90
100

Características del audio en el dominio del tiempo

Time domain Features

-Zero crossing rate, Modified ZCR

-Amplitude based features: AD, ADSR, log attack time, shimmer

-Energy based features: Short time energy, Volume, Temporal Centroid

-Auto-correlation based features

- Rhythm based features

Ejemplos:

Zero-Crossing Rate (ZCR)

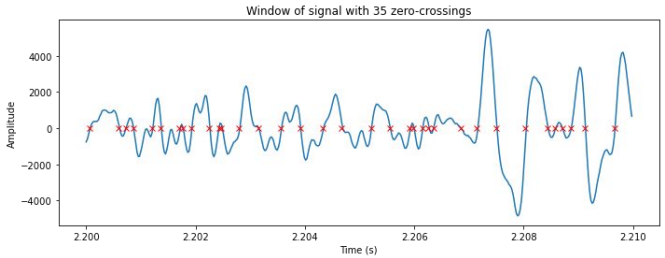

Definición:

La Tasa de Cruces por Cero (ZCR) mide el número de veces que una señal de audio cambia de signo (de positivo a negativo o viceversa) en un segmento temporal, normalizado por la longitud del frame.

Fórmula:

$$Z(i) = \frac{1}{2N} \sum_{n=1}^{N} |\mathrm{sgn}[x_i(n)] - \mathrm{sgn}[x_i(n-1)]|$$

Referencia: Sharma, G., Umapathy, K., & Krishnan, S. (2020). Trends in audio signal feature extraction methods. *Applied Acoustics, 158*, 107020. https://doi.org/10.1016/j.apacoust.2019.107020

Características del audio en el dominio del tiempo

Time domain Features

-Zero crossing rate, Modified ZCR

-Amplitude based features: AD, ADSR, log attack time, shimmer

-Energy based features: Short time energy, Volume, Temporal Centroid

-Auto-correlation based features

- Rhythm based features

Ejemplos:

Short-Time Energy (STE)

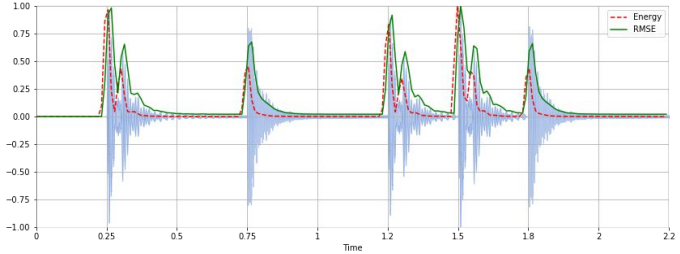

Definición:

La Energía de Corto Tiempo calcula la energía promedio en un frame de la señal, útil para identificar segmentos sonoros vs. silencios.

Fórmula:

$$E(i) = \frac{1}{N} \sum_{n=0}^{N-1} x_i^2(n)$$

Referencia: Sharma, G., Umapathy, K., & Krishnan, S. (2020). Trends in audio signal feature extraction methods. *Applied Acoustics, 158*, 107020. https://doi.org/10.1016/j.apacoust.2019.107020

Características del audio en el dominio de la frecuencia

Frequency Domain Features

-Auto-regression based features: LPC, CELP, LSF

- Peak Frequency
- MSAF-MULTIEXPANDED
- SMOFS-MULTIEXPANDED
- STFT/Time frequency based: time-frequency matrix, sub-band energy ratio, spectrum envelope, SPSF, GDF
- EMS based
- LTAS based
- Chroma related features
- Tonality based features: FF, pitch histogram, pitch profile, harmonicity, harmonic-to-noise ratio, jitter
- Spectrum shape based features: Spectral Centroid, Spectral centre, spectral roll-off, spectral spread, skewness, kurtosis, Spectral slope, spectral decrease, bandwidth, spectral flatness, spectral crest factor, entropy, flux, OBSC.

Ejemplos:

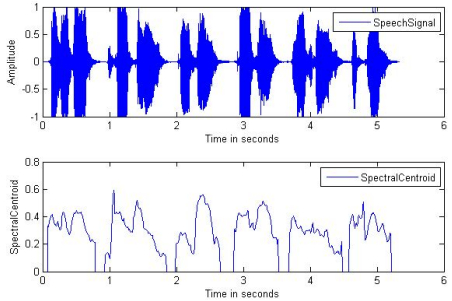

Spectral Centroid (Centroide Espectral)

Definición:

El Spectral Centroid indica el "centro de gravedad" del espectro de frecuencia de una señal de audio. Representa el promedio ponderado de las frecuencias presentes en la señal, donde los pesos son las magnitudes espectrales.

Fórmula:

$$\text{Spectral Centroid} = \frac{\sum_{k=b_1}^{b_2} f_k \cdot |X(k)|}{\sum_{k=b_1}^{b_2} |X(k)|}$$

Referencia: Sharma, G., Umapathy, K., & Krishnan, S. (2020). Trends in audio signal feature extraction methods. *Applied Acoustics, 158*, 107020. https://doi.org/10.1016/j.apacoust.2019.107020

Características del audio en el dominio de la frecuencia

Frequency Domain Features

-Auto-regression based features: LPC, CELP, LSF

- Peak Frequency
- MSAF-MULTIEXPANDED
- SMOFS-MULTIEXPANDED
- STFT/Time frequency based: time-frequency matrix, sub-band energy ratio, spectrum envelope, SPSF, GDF
- EMS based
- LTAS based
- Chroma related features
- Tonality based features: FF, pitch histogram, pitch profile, harmonicity, harmonic-to-noise ratio, jitter
- Spectrum shape based features: Spectral Centroid, Spectral centre, spectral roll-off, spectral spread, skewness, kurtosis, Spectral slope, spectral decrease, bandwidth, spectral flatness, spectral crest factor, entropy, flux, OBSC.

Ejemplos:

Spectral Bandwidth

(Ancho de Banda Espectral)

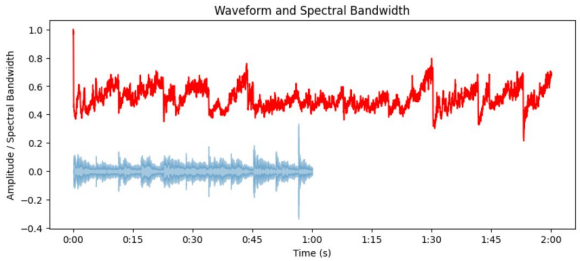

Definición:

El Spectral Bandwidth mide la dispersión del espectro alrededor del Spectral Centroid. Indica cuán "ancho" es el rango de frecuencias que contribuyen significativamente a la señal.

Fórmula:

$$\text{Spectral Bandwidth} = \sqrt{\frac{\sum_{k=b_1}^{b_2} (f_k - \text{Centroid})^2 \cdot |X(k)|}{\sum_{k=b_1}^{b_2} |X(k)|}}$$

Referencia: Sharma, G., Umapathy, K., & Krishnan, S. (2020). Trends in audio signal feature extraction methods. *Applied Acoustics, 158*, 107020. https://doi.org/10.1016/j.apacoust.2019.107020

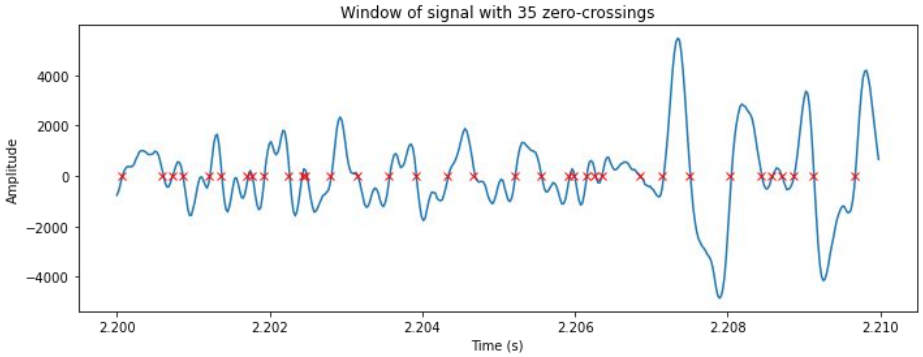
Window of signal with 35 zero-crossings
Amplitude
Time (s)

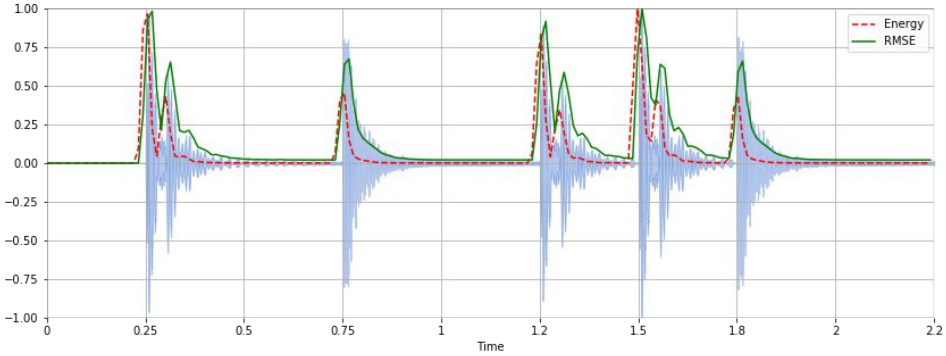
Energy
RMSE
Time

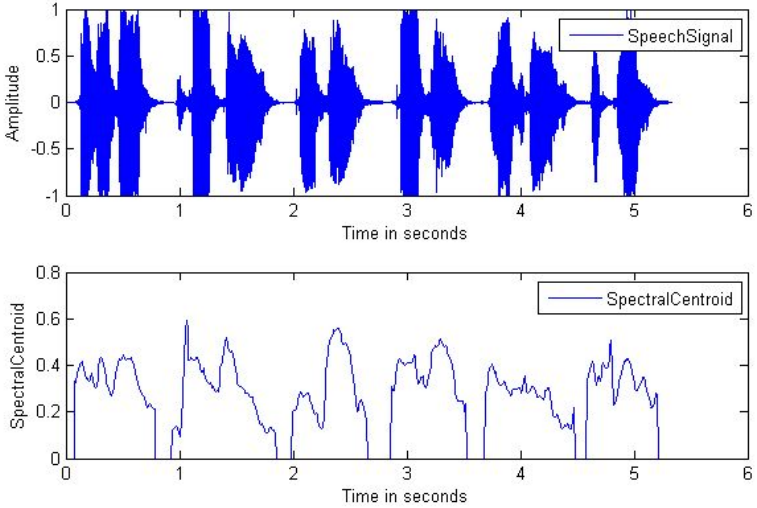
SpeechSignal
Amplitude
Time in seconds
SpectralCentroid
SpectralCentroid
Time in seconds

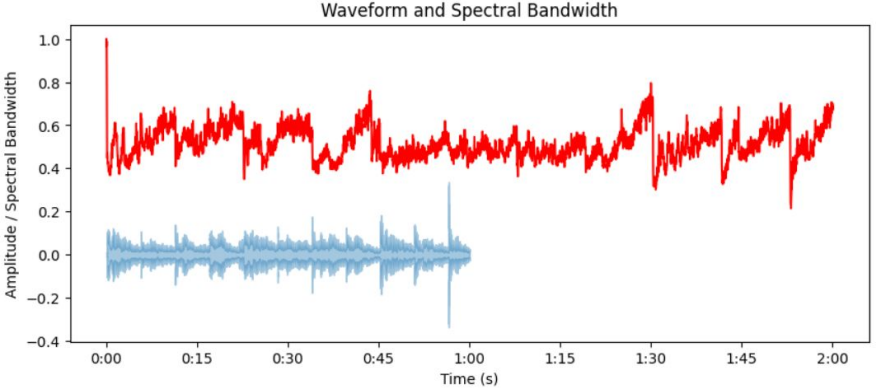
Waveform and Spectral Bandwidth
Amplitude / Spectral Bandwidth
Time (s)

Características del audio en tiempo-frecuencia

Estas técnicas permiten analizar señales de audio en dos dimensiones (tiempo y frecuencia), capturando información no estacionaria y patrones espectrales dinámicos.

Espectrograma

Definición:

Un espectrograma es una representación visual 2D de la energía espectral de una señal a lo largo del tiempo. Se calcula aplicando la Transformada de Fourier de Corto Tiempo (STFT) y graficando la magnitud en escala logarítmica (dB).

Cómo se calcula:

1. Segmentación: La señal se divide en ventanas solapadas (ej. Hamming, Hanning).
2. STFT: Se aplica la FFT a cada ventana.
3. Magnitud al cuadrado: Se calcula $|X(t,f)|^2$ para obtener la potencia espectral.

Referencia: Sharma, G., Umapathy, K., & Krishnan, S. (2020). Trends in audio signal feature extraction methods. *Applied Acoustics, 158*, 107020. https://doi.org/10.1016/j.apacoust.2019.107020

Características del audio en tiempo-frecuencia

Espectrograma Mel (Mel Spectrogram)

Definición:

Un espectrograma Mel aplica un banco de filtros Mel al espectrograma tradicional, imitando la percepción humana del tono (no lineal en Hz).

Pasos:

1. STFT: Igual que el espectrograma clásico.
2. Banco de filtros Mel:

Referencia: Sharma, G., Umapathy, K., & Krishnan, S. (2020). Trends in audio signal feature extraction methods. *Applied Acoustics, 158*, 107020. https://doi.org/10.1016/j.apacoust.2019.107020

Características del audio en tiempo-frecuencia

MFCC (Mel-Frequency Cepstral Coefficients)

Definición:

Los MFCC son coeficientes que representan la envolvente espectral en la escala Mel, obtenidos mediante la Transformada Cepstral. Son el estándar en reconocimiento de voz y procesamiento de audio.

Pasos de cálculo:

1. Espectrograma Mel: Como se describió arriba.
2. Logaritmo: Para comprimir dinámicamente la energía $(\log(E))$
3. DCT (Transformada Discreta del Coseno): Extrae los coeficientes cepstrales (primeros 12–20 retienen la información principal).

Referencia: Sharma, G., Umapathy, K., & Krishnan, S. (2020). Trends in audio signal feature extraction methods. *Applied Acoustics, 158*, 107020. https://doi.org/10.1016/j.apacoust.2019.107020

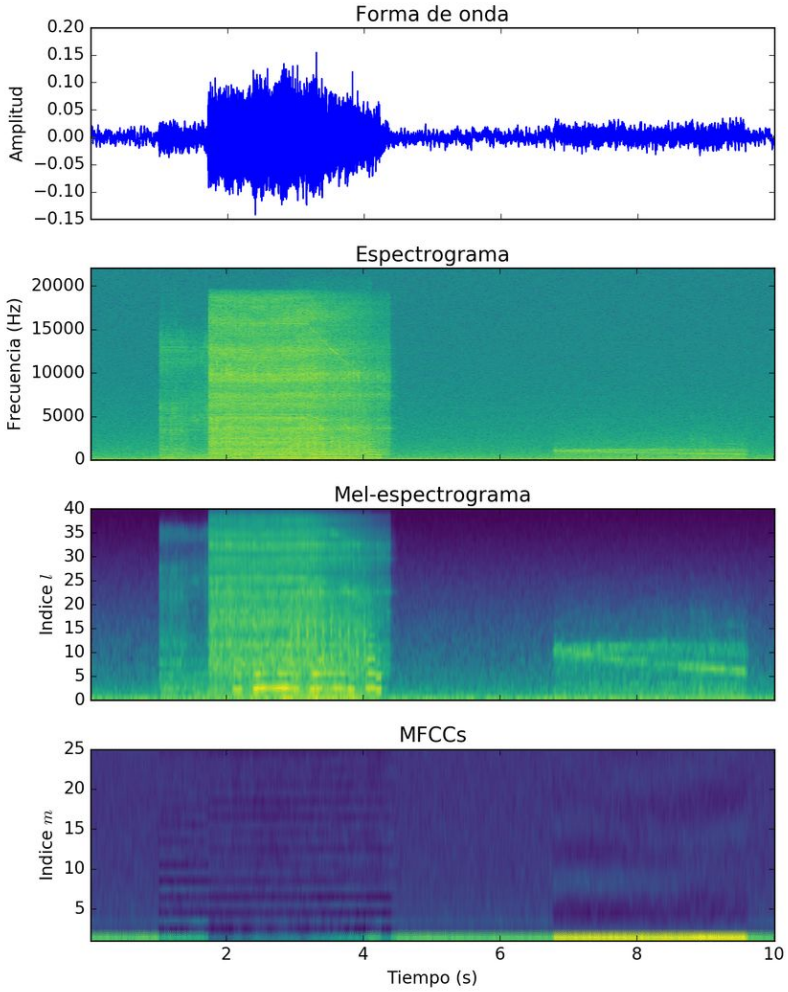
Forma de onda
Amplitud
0.20
0.15
0.10
0.05
0.00
−0.05
−0.10
−0.15
Espectrograma
Frecuencia (Hz)
20000
15000
10000
5000
0
Mel-espectrograma
Indice l
40
35
30
25
20
15
10
5
0
MFCCs
Indice m
25
20
15
10
5
2
4
6
8
10
Tiempo (s)

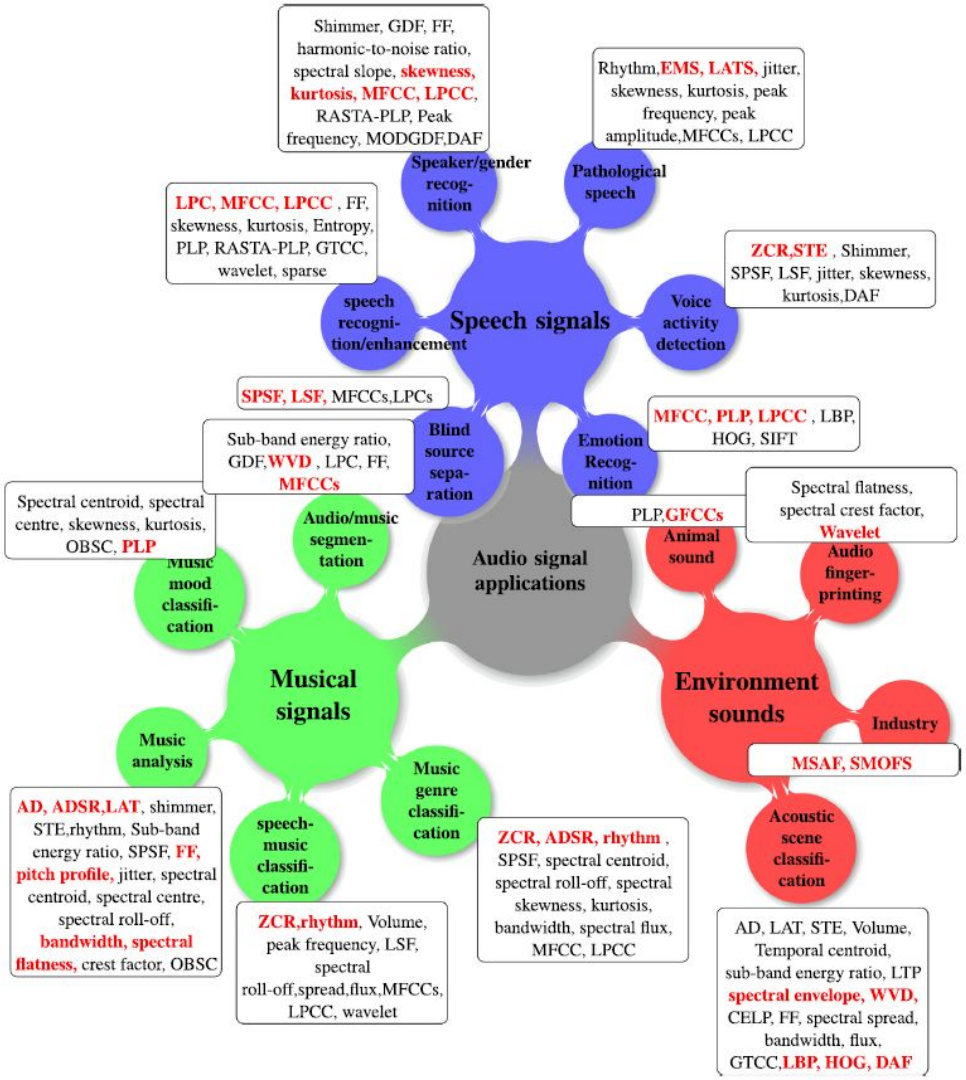
Audio signal applications
Speech signals
Speaker/gender recog-nition
Shimmer, GDF, FF, harmonic-to-noise ratio, spectral slope, skewness, kurtosis, MFCC, LPCC, RASTA-PLP, Peak frequency, MODGDF,DAF
Pathological speech
Rhythm,EMS, LATS, jitter, skewness, kurtosis, peak frequency, peak amplitude,MFCCs, LPCC
speech recogni-tion/enhancement
LPC, MFCC, LPCC , FF, skewness, kurtosis, Entropy, PLP, RASTA-PLP, GTCC, wavelet, sparse
Voice activity detection
ZCR,STE , Shimmer, SPSF, LSF, jitter, skewness, kurtosis,DAF
Blind source sepa-ration
SPSF, LSF, MFCCs,LPCs
Emotion Recog-nition
MFCC, PLP, LPCC , LBP, HOG, SIFT
Musical signals
Audio/music segmen-tation
Sub-band energy ratio, GDF,WVD , LPC, FF, MFCCs
Music mood classifi-cation
Spectral centroid, spectral centre, skewness, kurtosis, OBSC, PLP
Music analysis
AD, ADSR,LAT, shimmer, STE,rhythm, Sub-band energy ratio, SPSF, FF, pitch profile, jitter, spectral centroid, spectral centre, spectral roll-off, bandwidth, spectral flatness, crest factor, OBSC
speech-music classifi-cation
ZCR,rhythm, Volume, peak frequency, LSF, spectral roll-off,spread,flux,MFCCs, LPCC, wavelet
Music genre classifi-cation
ZCR, ADSR, rhythm , SPSF, spectral centroid, spectral roll-off, spectral skewness, kurtosis, bandwidth, spectral flux, MFCC, LPCC
Environment sounds
Animal sound
PLP,GFCCs
Audio finger-printing
Spectral flatness, spectral crest factor, Wavelet
Industry
MSAF, SMOFS
Acoustic scene classifi-cation
AD, LAT, STE, Volume, Temporal centroid, sub-band energy ratio, LTP spectral envelope, WVD, CELP, FF, spectral spread, bandwidth, flux, GTCC,LBP, HOG, DAF

Ejercicios e información extra

https://musicinformationretrieval.com/index.html

https://www.youtube.com/@ValerioVelardoTheSoundofAI

Utilizando los jupyters “zcr” y “energy”:

- Ejecuta y analiza la extracción de diferentes características de audio . Coloca comentarios relevantes en cada celda.

Continuar con en el análisis del Jupyter “MeIA audio”, sección Tema 5, para la extracción de espectrogramas.

- Completa las líneas de código necesarias para que ejecute. Presta mucha atención durante la explicación para que puedas hacerlo correctamente.

Tema 6.
Construcción de un modelo de aprendizaje profundo para clasificación de audio

6.1 Ejemplo de arquitectura típica CNN (Convolutional Neural Network) para audio

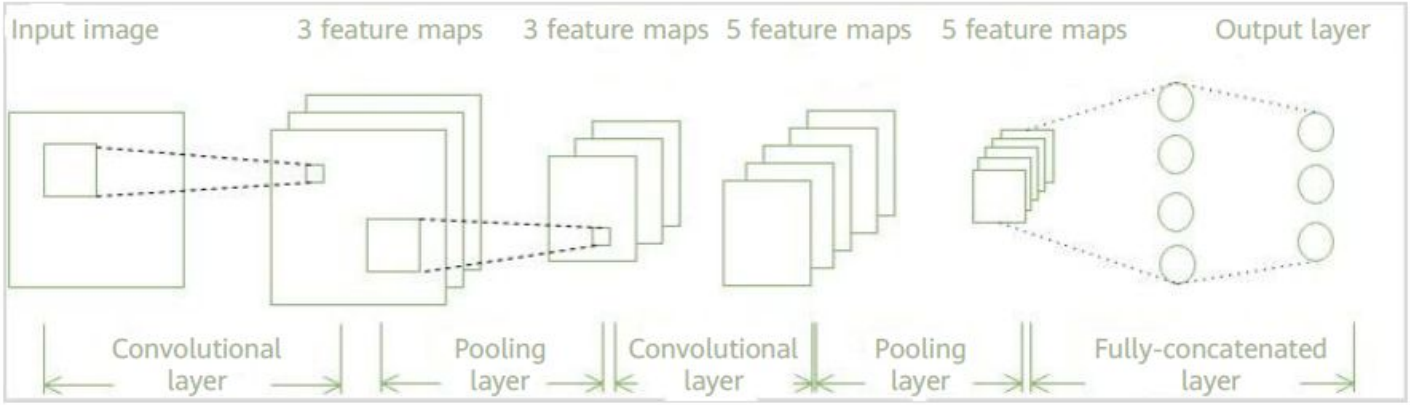

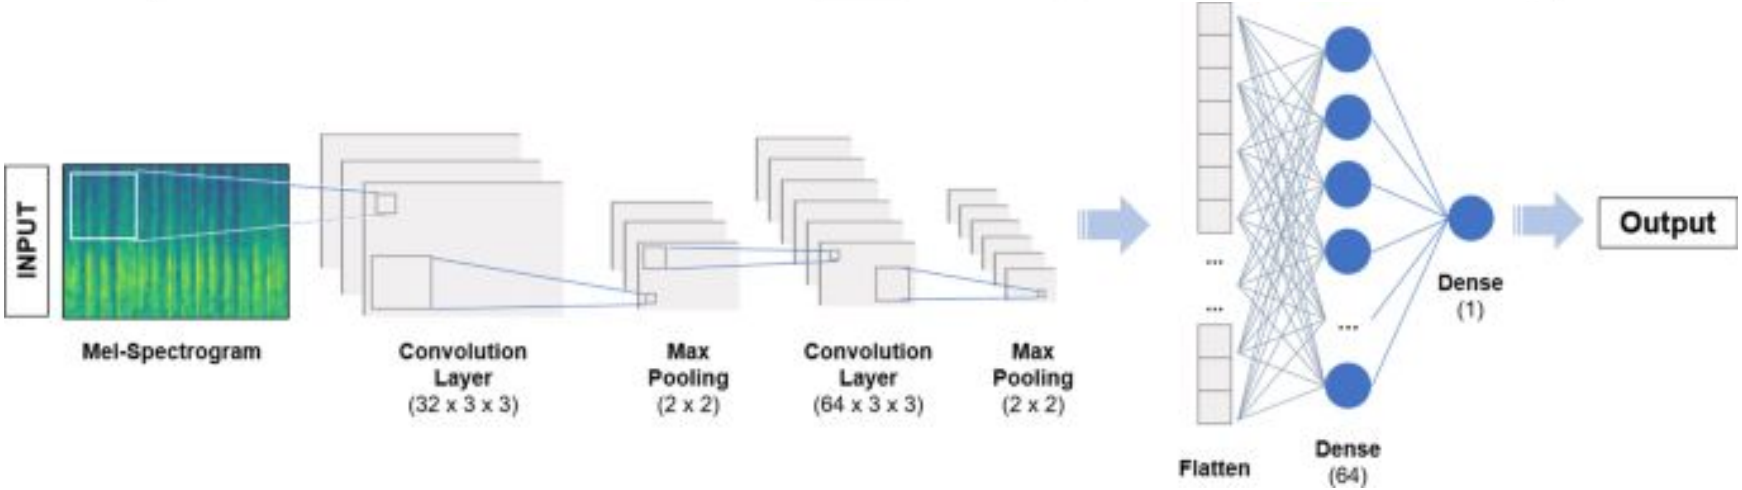

Elementos de la arquitectura de CNN

Entrada de 1 canal (a diferencia del uso clásico para imágenes a color, 3 canales).

Capa Convolucional (*Convolutional Layer*)

- Función: Extrae características locales mediante filtros/kernels que se deslizan sobre la entrada.
- Parámetros clave:
  - `kernel_size`: Tamaño del filtro (ej. 3×3).
  - `stride`: Paso de desplazamiento del filtro.
  - `padding`: Añade ceros para conservar dimensiones.
- Ejemplo en audio:
  - Detecta patrones como armónicos en espectrogramas.

Capa de *Pooling* (Submuestreo)

- Reduce dimensionalidad y preserva características dominantes:
  - Max Pooling: Toma el valor máximo en una ventana (ej. 2×2).
  - Average Pooling: Promedia los valores.
- Propósito:
  - Hacer el modelo invariante a pequeñas traslaciones.

Capa Fully Connected (*Dense*)

- Al final de la CNN: Conecta todas las neuronas para clasificación/regresión.
- Ejemplo:
  - Clasificar instrumentos musicales a partir de features extraídas.

Tema 7.
Entrenamiento del modelo

7.1 Preparación del conjunto de datos

División básica del dataset para la evaluación del modelo

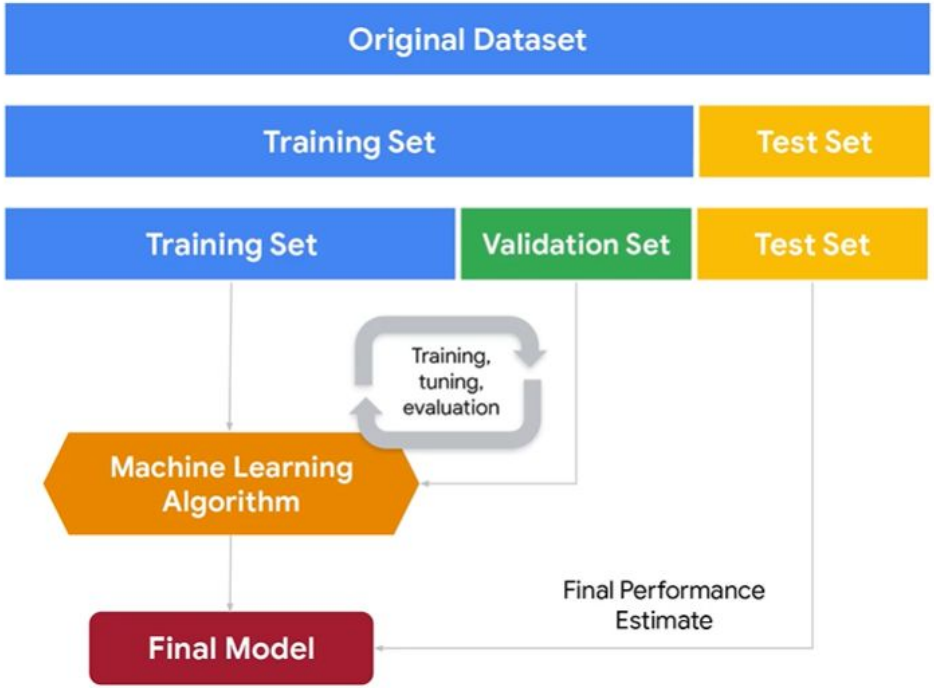

7.1 Preparación del conjunto de datos

Creación de lotes y precarga para un entrenamiento eficiente

Lote: Un conjunto de N muestras del conjunto de datos. El tamaño del lote es un hiperparámetro que determina el número de muestras con las que trabajar antes de actualizar los parámetros internos del modelo.

Gradiente descendiente por lote (BGD)

Gradiente descendiente estocástico (SGD)

Gradiente descendiente por minilote

Precarga de Lotes (Batch Prefetching) para Entrenamiento Eficiente
La precarga de lotes es una técnica crítica para optimizar el flujo de datos durante el entrenamiento de modelos de deep learning, evitando cuellos de botella al solapar la carga de datos con el cálculo de gradientes.

1. Carga y preprocesamiento del siguiente lote (batch) en CPU/RAM.
2. Cálculo de gradientes del lote actual en GPU.

Gradiente descendiente por lote (BGD):

Este método utiliza **todo el conjunto de datos** para calcular el gradiente de la función de pérdida. Los parámetros se actualizan una sola vez por época.
Ventajas: Proporciona una estimación estable del gradiente, que puede conducir a la convergencia al mínimo global para funciones de pérdida convexas.
Contras: Puede ser costoso y lento desde el punto de vista computacional, especialmente para grandes conjuntos de datos, ya que requiere cargar y procesar todo el conjunto de datos a la vez.

Gradiente descendiente estocástico (SGD):

Este enfoque actualiza los parámetros del modelo utilizando sólo **un ejemplo de entrenamiento cada vez**.
Ventajas: Las actualizaciones más rápidas pueden conducir a una convergencia más rápida y pueden ayudar a escapar de los mínimos locales debido al ruido introducido por el uso de muestras individuales.
Contras: El camino hacia la convergencia puede ser ruidoso y menos estable, pudiendo oscilar alrededor del mínimo en lugar de estabilizarse.

Gradiente descendiente por mini lotes:

Este método logra un equilibrio entre el descenso de gradiente por lotes y estocástico utilizando un pequeño subconjunto seleccionado aleatoriamente (minilotes). Los parámetros se actualizan después de procesar cada minilote.
Ventajas: Combina las ventajas de ambos métodos.
Contras: La elección del tamaño del minilote puede afectar al comportamiento de la convergencia, por lo que puede ser necesario ajustarlo.

7.2 Entrenamiento del modelo

Monitoreo de la pérdida y la exactitud

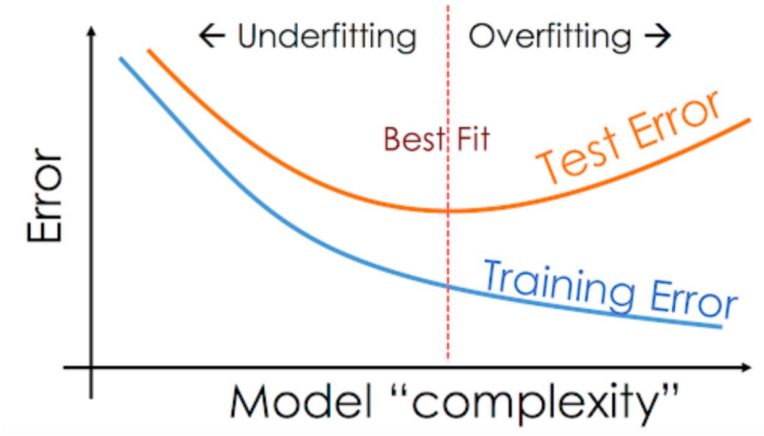

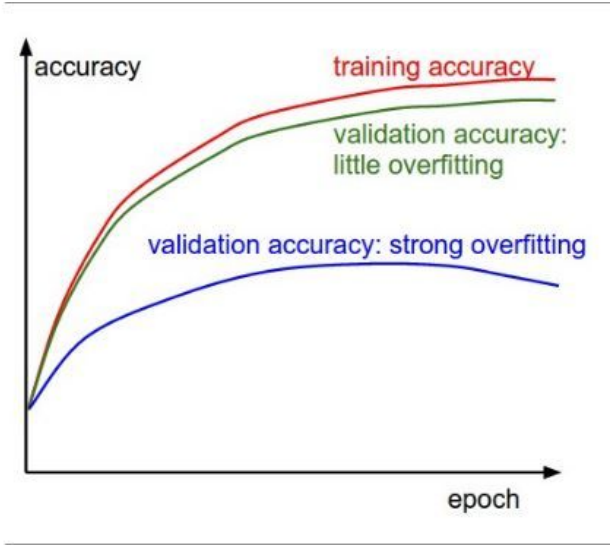

En el caso de overfitting (sobreajuste):
El Dropout es una técnica de regularización que apaga aleatoriamente un porcentaje de neuronas durante el entrenamiento para prevenir el overfitting. Es una capa configurable en la arquitectura.

Ejercicios

Continuar con en el análisis del Jupyter “MeIA audio”, secciones Tema 6 y Tema 7, para experimentar con diferentes configuraciones de hiperparámetros para el entrenamiento.

Algunas modificaciones para pruebas pueden ser:

- Agregando capas de pooling entre las convolucionales.
- Agregando una capa más de convolucional con el doble de filtros.
- Incrementando o decrementando épocas. Toma esta decisión basado en las gráficas de exactitud y pérdida. (considera que entre más épocas, mayor tiempo de entrenamiento)
- Eliminando el resizing para que el tensor de entrada sea el completo.
- Haciendo que clasifiques menos clases (3 por ejemplo).

El objetivo es obtener una exactitud mayor al 90%, con la menor cantidad de parámetros posibles y el menor tiempo de entrenamiento.

Ve anotando tus reflexiones mientras haces tus pruebas, y compártelas en el foro. Al menos intenta hacer 5 pruebas con configuraciones diferentes. Reporta completo tu mejor resultado indicando indicando arquitectura de la CNN, número de clases, épocas, y cualquier otro parámetro relevante.

Tema 8.
Despliegue y evaluación

8.2 Métricas de evaluación del desempeño

- Terms:
  - P: positive, indicating the number of real positive cases in the data.
  - N: negative, indicating the number of real negative cases in the data.
  - TP : true positive, indicating the number of positive cases that are correctly classified.
  - TN: true negative, indicating the number of negative cases that are correctly classified.
  - FP: false positive, indicating the number of positive cases that are incorrectly classified.
  - FN: false negative, indicating the number of negative cases that are incorrectly classified.

Predicted / Actual	Yes	No	Total
Yes	TP	FN	P
No	FP	TN	N
Total	P'	N'	$P+N$

Confusion matrix

- The confusion matrix is an $m \times m$ table at minimum. The entry $CM_{i,j}$ in the first m rows and m columns indicates the number of cases that belong to class i but are labeled as j.
  - For classifiers with high accuracy, most of the cases should be represented by entries on the diagonal of the confusion matrix from $CM_{1,1}$ to $CM_{m,m}$,while other entries are 0 or close to 0. That is, FP and FN are close to 0.

Measurement	Formula
Accuracy, recognition rate	$\frac{TP + TN}{P + N}$
Error rate, misclassification rate	$\frac{FP + FN}{P + N}$
True positive rate, sensitivity, recall	$\frac{TP}{P}$
True negative rate, specificity	$\frac{TN}{N}$
Precision	$\frac{TP}{TP + FP}$
F_1 value, harmonic mean of precision and recall	$\frac{2 \times precision \times recall}{precision + recall}$

Performance Evaluation of Machine Learning - Example

- In this example, an ML model was trained to identify an image of a cat. To evaluate the model's performance, 200 images were used, of which 170 of them were cats.
- The model reported that 160 images were cats.

Precision: $P = \frac{TP}{TP+FP} = \frac{140}{140+20} = 87.5\%$

Recall: $R = \frac{TP}{P} = \frac{140}{170} = 82.4\%$

Accuracy: $ACC = \frac{TP+TN}{P+N} = \frac{140+10}{170+30} = 75\%$

Predicted / Actual	yes	no	Total
yes	140	30	170
no	20	10	30
Total	160	40	200

Umbral de desición

Two types of **error**

	Actual Disease = Yes	Actual Disease = No
Predicted Disease = Yes	True Positive	False Positive ***Type 1 Error***
Predicted Disease = No	False Negative ***Type 2 Error***	True Negative

Precision

If we optimize our model for **high precision**

We **minimize** *Type 1* Errors
(fewer false positives)

We **increase** *Type 2* Errors
(more false negatives)

Recall

If we optimize our model for **high recall**

We **minimize** *Type 2* Errors
(fewer false negatives)

We **increase** *Type 1* Erro
(more false positives)

8.1 Evaluación de audios grabados y capturados al momento

En el jupyter notebook, entrenando solo para las clases up, down y stop.

- Prueba 30 audios independientes (10 por clase) grabados por ti o personas cercanas e inferidos por el modelo final que elegiste.
- Sube tus audios al drive común.
- Evalúa otros 30 audios de otro compañero o compañera.
- Comparte en el foro tu matriz de confusión de tu mejor resultado y tus reflexiones.